

# Probability & Statistics

## 1. 样本空间

## 2. 事件

### 事件的运算与关系

- 和事件 (并集)  $A \cup B = \{x | x \in A \text{ or } x \in B\} \Leftrightarrow A \text{与} B \text{至少有一发生}$
- 积事件 (交集)  $A \cap B = \{x | x \in A \text{ and } x \in B\} \Leftrightarrow A \text{与} B \text{同时发生}$
- $\bigcup_{i=1}^n A_i \Leftrightarrow$  该和事件发生  $\Leftrightarrow A_1, A_2, \dots, A_n$  中至少有一发生
- $\bigcap_{i=1}^n A_i \Leftrightarrow$  该积事件发生  $\Leftrightarrow A_1, A_2, \dots, A_n$  同时发生
- 当  $AB = \emptyset$ , 称事件  $A$  与  $B$  不相容或互斥
- 差事件  $A - B = \{x \in A \text{ and } x \notin B\}$
- $A$  的逆事件(对立事件)  $A \cup \bar{A} = S, A\bar{A} = \emptyset, \bar{\bar{A}} = A$
- 引入逆事件后,  $A$  与  $B$  的差事件可表示为  $A - B = A\bar{B} = A \cup B - B = A - AB$

### 事件的运算定律(集合的运算定律)

- 交换律  $A \cup B = B \cup A, A \cap B = B \cap A$
- 结合律  $A \cup (B \cap C) = (A \cup B) \cap C, A \cap (B \cup C) = (A \cap B) \cup C$
- 分配律  $A \cup (B \cap C) = (A \cup B) \cap (A \cup C), A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
- 对偶律  $\overline{A \cup B} = \bar{A} \cap \bar{B}, \overline{A \cap B} = \bar{A} \cup \bar{B}$
- 对偶律推广  $\overline{\bigcap_{i=1}^n A_i} = \bigcup_{i=1}^n \bar{A}_i, \overline{\bigcup_{i=1}^n A_i} = \bigcap_{i=1}^n \bar{A}_i$
- Attention:  $\overline{AB} \neq \bar{A}\bar{B}, \overline{A\bar{B}} = \bar{A} \cap B, \overline{\bar{A}B} = A \cap \bar{B}$
- $\overline{AB} = (\bar{A}\bar{B}) \cup A\bar{B} \cup \bar{A}B \Leftrightarrow A, B \text{不同时发生} = A, B \text{都不发生} \cup A \text{发生而} B \text{不发生} \cup B \text{发生而} A \text{不发生}$

Summary:

- 至少有一发生
  - 和事件
  - $A \cup B$
  - $\bigcup_{i=1}^n A_i$
- 同时发生
  - 积事件
  - $A \cap B$
  - $\bigcap_{i=1}^n A_i$
- 都不发生
  - 至少有一发生的逆事件
  - $\overline{A \cup B} = \bar{A} \cap \bar{B}$
  - $\overline{\bigcup_{i=1}^n A_i} = \bigcap_{i=1}^n \bar{A}_i$
- 不同时发生  $\Leftrightarrow$  至少有一事件不发生  $\Leftrightarrow$  最多有  $n-1$  个事件发生
  - 同时发生的逆事件
  - $\overline{A \cap B} = \bar{A} \cup \bar{B}$
  - $\overline{\bigcap_{i=1}^n A_i} = \bigcup_{i=1}^n \bar{A}_i$

### 3. 频率

频率的稳定值  $\rightarrow p \rightarrow$  概率

### 4. 概率

#### 概率的统计性定义

当试验的次数增加时,随机事件A发生的频率的稳定值p称为概率,记为 $P(A) = p$

#### 概率的公理化定义

设随机试验对应的样本空间为S,对每个事件A定义 $P(A)$ 满足三公理:

- 非负性:  $P(A) \geq 0$
- 规范性:  $P(S) = 1$
- 可列可加性:  $A_i A_j = \emptyset, i \neq j \Rightarrow P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$

#### 公理化定义推导出的性质

1.  $P(\emptyset) = 0$
2.  $P(A) = 1 - P(\bar{A})$
3. (有限可加性)  $A_1, A_2, \dots, A_n, A_i A_j = \emptyset, i \neq j \Rightarrow P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$
4.  $A \subset B \Rightarrow P(B - A) = P(B) - P(A) \geq 0$ ; 一般情况:  $P(B - A) = P(B) - P(AB)$
5. 概率加法公式:  
$$P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i A_j) + \sum_{1 \leq i < j < k \leq n} P(A_i A_j A_k) + \dots + (-1)^{i-1} P(A_1 A_2 \dots A_n)$$

#### 古典概型(等可能概型)

样本点有限且等可能

基本就是数数问题

1. 抽球问题(放回/不放回)(考虑顺序/不考虑顺序)
2. 分房问题
3. 随机取数问题

#### 条件概率

$$P(B) \neq P(B|A)$$

缩小的样本空间:事件A的发生改变了样本空间,使它由原来的S缩减为新的样本空间

$$S_A = A$$

以A的视角来看待B事件: B在A中所占的比例

#### 定义

$$P(B|A) = \frac{P(AB)}{P(A)}, P(A) > 0$$

#### 性质

$P(\bullet|A)$  是概率, 因而满足三性:

- 非负性:  $P(B|A) \geq 0$
- 规范性:  $P(S|A) = 1$
- 可列可加性:  $B_1, B_2, \dots, B_i B_j = \emptyset, i \neq j \Rightarrow P(\bigcup_{i=1}^{\infty} B_i | A) = \sum_{i=1}^{\infty} P(B_i | A)$

进而满足上述所有的概率性质

- $P(B|A) = 1 - P(\bar{B}|A)$
- $P(B \cup C|A) = P(B|A) + P(C|A) - P(BC|A)$
- $B \supset C \Rightarrow P(B|A) \geq P(C|A)$
- ...

乘法公式

$$P(AB) = P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$$

$$P(A_1 A_2 \dots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 A_2) \dots P(A_n|A_1 \dots A_{n-1})$$

全概率公式

定义

$$P(A) = \sum_{j=1}^n P(B_j) \cdot P(A|B_j)$$

证明

$$\because A = AS = AB_1 \cup AB_2 \cup \dots \cup AB_n,$$

$$AB_i AB_j = \emptyset, i \neq j$$

$$\therefore P(A) = \sum_{j=1}^n P(AB_j) \Leftrightarrow P(A) = \sum_{j=1}^n P(B_j) \cdot P(A|B_j)$$

样本空间的变换

$$\text{若设 } P(B_j) = p_j, P(A|B_j) = q_j, j = 1, 2, \dots, n$$

$$\text{则 } P(A) = \sum_{j=1}^n p_j q_j$$

**Bayes公式**

定理

设  $B_1, B_2, \dots, B_n$  为  $S$  的一个划分且  $P(B_i) > 0$ . 对  $P(A) > 0$  有 *Bayes* 公式 :

$$P(B_i|A) = \frac{P(B_i)P(A|B_i)}{\sum_{j=1}^n P(B_j)P(A|B_j)} = \frac{p_i q_i}{\sum_{j=1}^n p_j q_j}$$

分母即为全概率公式, 分子由乘法公式得到;  $P(B_i)$  为先验概率,  $P(B_i|A)$  为后验概率

**Note:**

1. 乘法公式:

$$P(B_i|A) \cdot P(A) = P(AB_i) = P(A|B_i) \cdot P(B_i) \Rightarrow P(B_i|A) = \frac{P(B_i)P(A|B_i)}{P(A)}$$

2. 全概率公式:  $P(A) = \sum_{j=1}^n P(AB_j) \Leftrightarrow P(A) = \sum_{j=1}^n P(B_j) \cdot P(A|B_j)$

事件的独立性

定义

设  $A, B$  是两随机事件, 如果  $P(AB) = P(A)P(B)$ , 则称  $A, B$  相互独立.

特点

- $A$  与  $B$  的对称性
- 不需要条件概率存在的条件, 即事件的概率可以为 0

$$\text{If: } P(A) > 0, P(B) > 0, \text{ then: } P(AB) = P(A)P(B) \Leftrightarrow P(B|A) = P(B) \Leftrightarrow P(A|B) = P(A)$$

性质

$A, B$  相互独立  $\Leftrightarrow \bar{A}, B$  相互独立  $\Leftrightarrow A\bar{B}$  相互独立  $\Leftrightarrow \bar{A} \cap \bar{B}$  相互独立

推广定义

设  $A_1, A_2, \dots, A_n$  为  $n$  个随机事件, 若对  $2 \leq k \leq n$ , 均有:

$$P(A_{i_1} A_{i_2} \dots A_{i_k}) = \prod_{j=1}^k P(A_{i_j})$$

则称  $A_1, A_2, \dots, A_n$  相互独立

## 5. 随机变量

中心问题: 将试验结果数量化

### 一维随机变量

定义

设随机试验的样本空间为  $S$ ,  $e$  为样本点, 若  $X = X(e)$  为定义在  $S$  上的实值单值函数, 则称  $X(e)$  为随机变量, 简称为  $X$ .

该变量实质上为一映射: 样本空间到实数上的映射

说明

- 随机变量  $X(e): S \rightarrow R$  为一映射, 其自变量具有随机性
- 随机事件可表示为  $A = \{e: X(e) \in I\} = \{X \in I\}, I \subset R$
- 映射的性质: 对于  $i \neq j$ , 必有  $\{X = i\} \cap \{X = j\} = \emptyset$

### 离散型随机变量

描述方式

- 分布律
- 分布函数

离散型随机变量的分布函数

一般地, 离散型随机变量的分布函数为阶梯函数.

设离散型随机变量  $X$  的分布律为  $P\{X = x_k\} = p_k, k = 1, 2, \dots$   $X$  的分布函数为

$$F(X) = \sum_{x_k \leq x} p_k$$

$F(X)$  在  $x = x_k, (k = 1, 2, \dots)$  处有跳跃, 其跳跃值为  $p_k = P\{X = x_k\} \rightarrow$  右连续

常见的离散型随机变量

1. 退化分布
2. 0-1分布/两点分布/Bernoulli分布  $\Leftrightarrow X \sim 0-1(p) \Leftrightarrow X \sim B(1, p)$
3. 二项分布 (*Binomial*) /  $n$ 重Bernoulli试验的分布  $\Leftrightarrow X \sim B(n, p)$
4. 泊松分布 (*Poisson*)  $\Leftrightarrow X \sim \pi(\lambda) \Leftrightarrow X \sim P(\lambda)$
5. 几何分布 (*Geometric*)  $\Leftrightarrow X \sim \text{Geom}(p)$

二项分布

$$P(X = k) = C_n^k p^k (1-p)^{n-k}, k = 0, 1, \dots, n.$$

泊松分布

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, k = 0, 1, 2, \dots, \lambda > 0$$

泰勒展开式

$$e^{\lambda} = \sum_{k=0}^{+\infty} \frac{\lambda^k}{k!}$$

作为二项分布的近似

n很大,p小时:  $\lambda = np$

几何分布

$$P(X = k) = p(1 - p)^{k-1}, k = 1, 2, 3, \dots$$

## 连续型随机变量

其定义是伴随着概率密度函数的定义产生的

### 描述方式

- 分布函数

### 定义

对于随机变量X的分布函数F(x),若存在非负的函数f(x),使对于任意实数x有:

$$F(x) = \int_{-\infty}^x f(t) dt$$

则称X为连续型随机变量,其中f(x)称为X的概率密度函数,简称概率密度,有时也写为  $f_x(x)$

### 概率密度函数的性质

- $f(x) \geq 0$
- $\because F(+\infty) = 1 \therefore \int_{-\infty}^{+\infty} f(x) dx = 1$
- $P(x_1 < X < x_2) = \int_{x_1}^{x_2} f(t) dt \Leftrightarrow P(X \in D) = \int_D f(x) dx \Rightarrow P(X = a) = 0, P(x_1 < X < x_2) = P(x_1 < X \leq x_2)$
- 在f(x)连续点x,  $F'(x) = f(x) \Rightarrow P(x < X \leq x + \Delta x) \approx f(x) \cdot \Delta x$
- f(x)的值可以大于1
- $f(x) \longleftrightarrow \frac{\int_{-\infty}^x f(t) dt}{\frac{d}{dx} F(x)} F(x)$

### 常见的连续型随机变量

- 均匀分布 (*Uniform*)  $\Leftrightarrow X \sim U(a, b) \Leftrightarrow X \sim Unif(a, b)$
- 指数分布 (*Exponential*)  $\Leftrightarrow X \sim E(\lambda) \Leftrightarrow X \sim Exp(\lambda)$
- 正态/高斯分布 (*Normal*)  $\Leftrightarrow X \sim N(\mu, \sigma^2)$

均匀分布

概率密度函数

$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in (a, b) \\ 0, & \text{else} \end{cases}$$

分布函数

$$F(x) = \begin{cases} 0, & x < a; \\ \frac{x-a}{b-a}, & a \leq x < b; \\ 1, & x \geq b. \end{cases}$$

性质

均匀分布具有等可能性,即X落入(a,b)中等长度的任意子区间上是等可能的

指数分布

概率密度函数

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0; \\ 0, & x \leq 0. \end{cases}$$

分布函数

$$F(x) = \begin{cases} 1 - e^{-\lambda x}, & x > 0; \\ 0, & x \leq 0. \end{cases}$$

性质

指数分布具有无记忆性

正态分布

概率密度函数

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < +\infty, (\sigma > 0)$$

标准正态分布的概率密度函数

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, (\sigma = 1, \mu = 0)$$

分布函数

$$F(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$$

标准正态分布的分布函数

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt, (\sigma = 1, \mu = 0)$$

$f(x)$  性质

- $f(x)$  关于  $x = \mu$  对称
- $f(x)$  在  $x = \mu$  达到最大值  $\frac{1}{\sqrt{2\pi}\sigma}$
- $f(x)$  的图像以  $Ox$  轴为渐近线且在  $x = \mu \pm \sigma$  处为拐点

$\Phi(x)$  性质

- $\Phi(-x) = 1 - \Phi(x)$
- $\Phi(\frac{x-\mu}{\sigma}) = F(x), x \in R \Leftrightarrow Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$
- $P\{a < X < b\} = \Phi(\frac{b-\mu}{\sigma}) - \Phi(\frac{a-\mu}{\sigma}) \Rightarrow 3\sigma$  准则

一维随机变量的函数的分布

对于  $Y = g(X)$ ,  $h(x)$  是  $g(x)$  的反函数 :

$$f_Y(y) = \begin{cases} f_X[h(y)]|h'(y)|, & \alpha < y < \beta; \\ 0, & \text{其他.} \end{cases}$$

一维随机变量的数字特征

一维随机变量的数学期望

## 一维离散型随机变量的数学期望

设离散型随机变量的分布律为:  $P\{X = x_i\} = p_i$ , 若如下级数绝对收敛则其为X的期望:

$$E(X) = \sum_{i=1}^{\infty} x_i p_i$$

### 常见离散型随机变量的期望

- $X \sim b(n, p) \rightarrow E(X) = np$
- $X \sim \pi(\lambda) \rightarrow E(X) = \lambda$
- $X \sim Ge(p) \rightarrow E(X) = \frac{1}{p}$

## 一维连续型随机变量的数学期望

设连续型随机变量X的概率密度函数为 $f(x)$ , 则当  $\Delta x (\Delta x > 0)$  充分小时, 随机变量X的取值落在区间  $(x, x + \Delta x]$  内的概率近似为  $f(x)\Delta x$ , 类似于离散型随机变量的期望定义, 有:

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx$$

### 常见连续型随机变量的期望

- $X \sim U(a, b) \rightarrow E(X) = \frac{a+b}{2}$
- $X \sim E(\lambda) \rightarrow E(X) = \frac{1}{\lambda}$
- $X \sim N(\mu, \sigma^2) \rightarrow E(X) = \mu$

## 一维随机变量函数的数学期望

▮  $g(x)$  要为实值连续函数

### 一维离散型随机变量函数的数学期望

$$E(Y) = E[g(X)] = \sum_{i=1}^{\infty} g(x_i) p_i$$

### 一维连续型随机变量函数的数学期望

$$E(Y) = E[g(X)] = \int_{-\infty}^{+\infty} g(x) f(x) dx$$

## 一维随机变量的方差

$$D(X) = Var(X) = E[X - E(X)]^2$$

$$D(X) = E(X)^2 - [E(X)]^2$$

### 常见随机变量的方差

- $X \sim b(1, p) \rightarrow D(X) = p(1-p)$
- $X \sim \pi(\lambda) \rightarrow D(X) = \lambda$
- $X \sim U(a, b) \rightarrow D(X) = \frac{(b-a)^2}{12}$
- $X \sim E(\lambda) \rightarrow D(X) = \frac{1}{\lambda^2}$
- $X \sim N(\mu, \sigma^2) \rightarrow D(X) = \sigma^2$